

第五周

第五周課程，主要是介紹了深度學習之中的**特徵學習**和**表徵學習**，以銜接之後的課程。

1. 特徵學習

特徵(feature)：是一種函數，可以擷取輸入的某些特性。例如：一個人的身高、體重、長相皆屬於特徵。

一個好的特徵需要具備的條件：

1. 有代表性：能輕易地用這個特徵分類。例如：可以用有無鬍鬚來區分狗和貓。但用有無尾巴則難以區分，即沒有代表性。
2. 要能容忍變異：意即當對此特徵做某種處理(例如對照片做翻轉)，還是可以看出此特徵。

而特徵又可以分為兩種：

1. 人工定義特徵：人類依照經驗和研究所定義出的特徵，通常定義過程會較繁雜。例如： $\phi(x)$, *kernel function*。
2. 自動學習特徵：
讓機器自行學習、為深度學習的特徵產出模式。
定義方式：利用**層次結構**，由簡單元素合成複雜特徵，和第一周提到的人類視覺處理過程相當類似。學習到的特徵會以特定的權重值(W)表示(可以以向量表示)。

2. 表徵學習

① 資料表徵(Representation)：

以不同的基底重新描述資料，以機器學習來說，就是將特徵壓縮成表徵
例如： 1164×7899 可以被分成 $2^2 \times 3^2 \times 97 \times 2633$ ，比較好計算。雖然
是以不同基底來描述，但是表徵要能維持資料的原始特性。

另外，有非分散式表徵和分散式表徵：

1. 非分散式表徵

表徵間並無空間差異(內積=0)，例如：A 的表徵向量為 $[\dots \ 0 \ 1 \ 0 \ \dots]$ ；B 的表徵向量為 $[\dots \ 1 \ 0 \ 0 \ \dots]$ ，此兩者屬於非分散式表徵。


2. 分散式表徵

表徵間有空間差異(內積 $\neq 0$)


② 表徵學習

1. 主成分分析(PCA)

其方法主要是通過對共變異數矩陣進行特徵分解，以得出數據的主成分（即特徵向量）與它們的權值（即特徵值）。其結果可以理解為尋找哪一個方向的投影向量對變異數的影響最大。換而言之，PCA 提供了一種降低數據維度的有效辦法（將數據投影之後可降低維度）；如果分析者在原數據中除掉最小的特徵值所對應的成分，那麼所得的低維度數據必定是最優化的（也即，這樣降低維度必定是失去訊息最少的方法）。主成分分析在分析複雜數據時尤為有用，比如人臉識別。

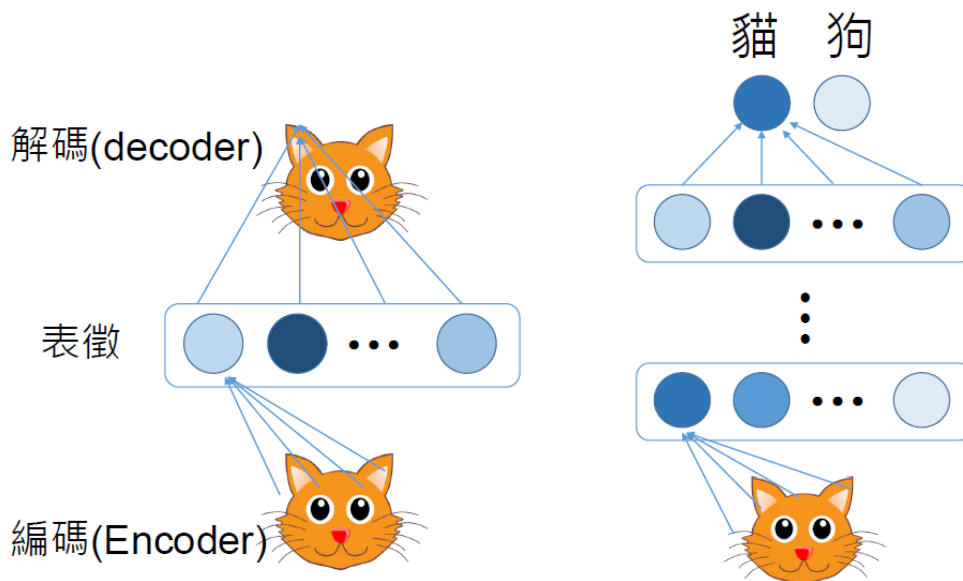


如上圖，我們想要找出資料在哪條軸上投影之後可以使變異數最大。（圖源）



上圖則是投影後的結果，可發現維度有效的被降低了。

2. 自動編碼機(Autoencoder)



如上左圖，將輸入資料的特徵壓縮成表徵(例如將圖片維度、大小壓縮)，之後訓練 decoder 可以將壓縮的表徵還原成接近原始的資料。而多層的表徵結構(如右圖)，則可以利用之前學習過的特徵來重新表達輸入資料，形成新的表徵，因此，我們可以理解為：表徵和特徵是共同學習出來的。

另外，深層表徵通常是決定結果的重要表徵，在許多問題中都十分重要。

參考資料

1. 機器/統計學習:主成分分析(PCA)

<https://chih-sheng-huang821.medium.com/%E6%A9%9F%E5%99%A8-%E7%B5%B1%E8%A8%88%E5%AD%B8%E7%BF%92-%E4%B8%BB%E6%88%90%E5%88%86%E5%88%86%E6%9E%90-principle-component-analysis-pca-58229cd26e71>